Calcolo Parallelo e Distribuito

Prodotto Matrice-Vettore
approfondimenti
Strategia 3 – parte1

Docente: Prof. L. Marcellino

Tutor: Prof. P. De Luca

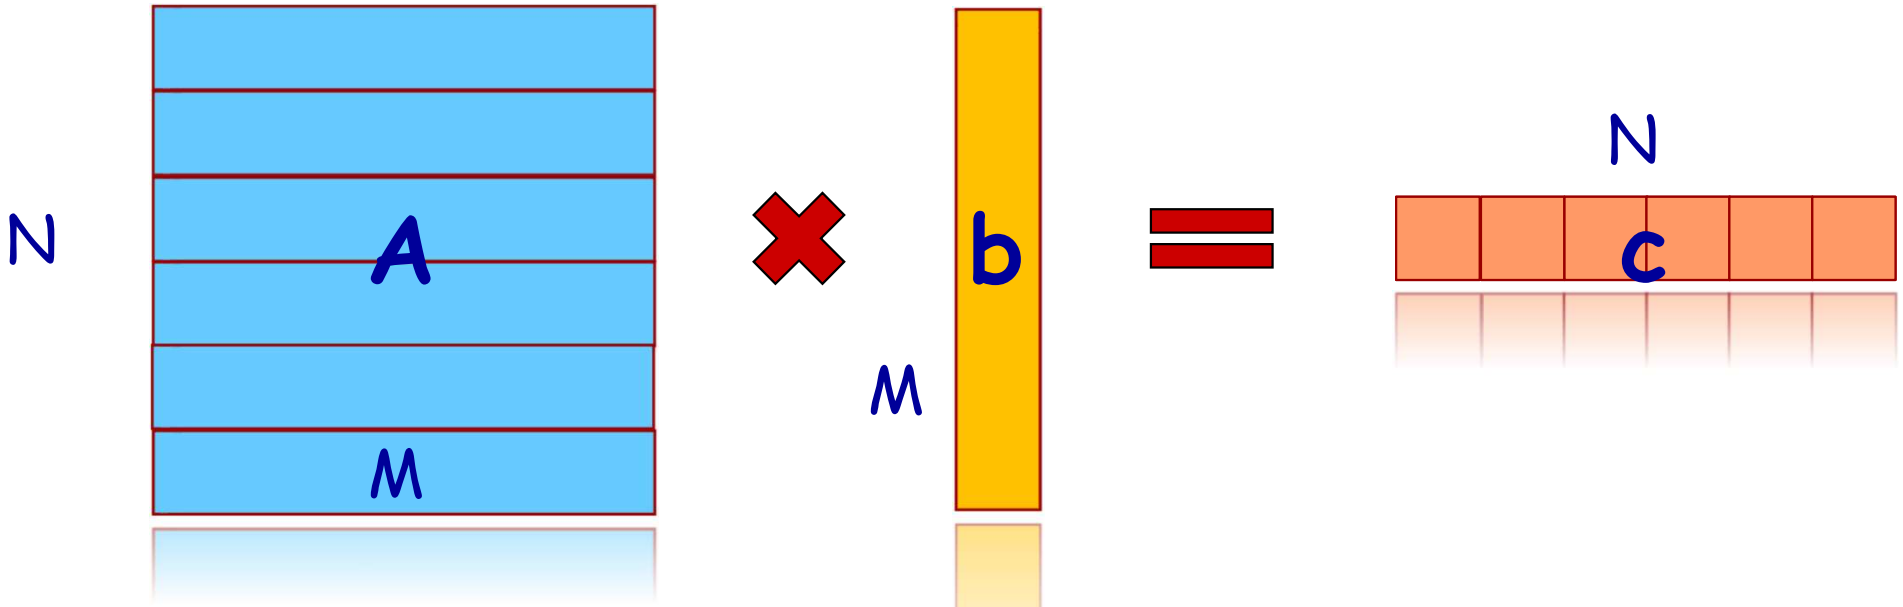
PROBLEMA: Prodotto Matrice-Vettore

algoritmo
per il calcolo del prodotto
di una matrice A per un vettore b:

Matrice A: N righe, M colonne, Vettore b: M elementi

Complessità computazionale dell'algoritmo sequenziale

Matrice A: N righe, M colonne, Vettore b: M elementi



In sequenziale, **N prodotti scalari di lunghezza M.**

Per fare 1 prodotto scalare di lunghezza M, devo fare:

M molt + (M-1) add

Complessità computazionale dell'algoritmo sequenziale

Matrice A: N righe, M colonne, Vettore b: M elementi

In sequenziale, **N prodotti scalari di lunghezza M**, cioè:

N[M molt + (M-1) add]

molt ~ add

$$T_1(N \times M) = N[2M-1]$$

PROBLEMA: Prodotto Matrice-Vettore

Progettazione
di un algoritmo parallelo
per architettura MIMD

per il calcolo del prodotto
di una matrice A pr un vettore b:

Matrice A: N righe, M colonne, Vettore b: M elementi

III STRATEGIA

Decomposizione 1: BLOCCHI di RIGHE

+

Decomposizione 2: BLOCCHI di COLONNE

=

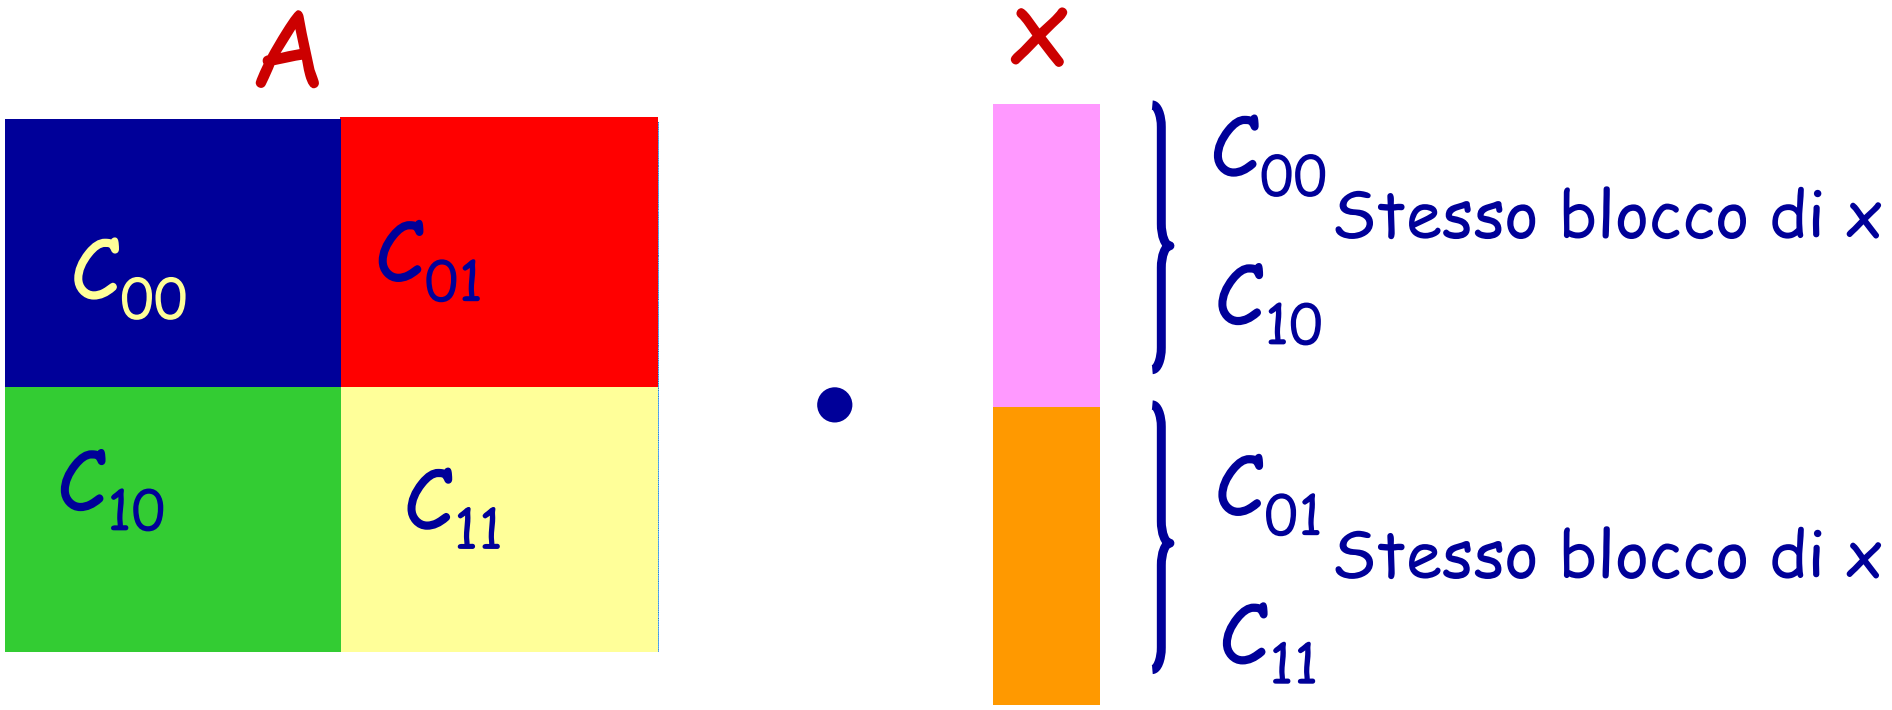
Decomposizione 3:

BLOCCHI RigheColonne

III Strategia: Esempio (4 core)

Distribuzione del lavoro sulla matrice A

per blocchi righe&colonne



Ogni core lavora col pezzo di x che gli serve

Esempio N = 6 , Core=4

c_{00}

$$a_{00} \cdot x_0 + a_{01} \cdot x_1 + a_{02} \cdot x_2$$
$$a_{10} \cdot x_0 + a_{11} \cdot x_1 + a_{12} \cdot x_2$$
$$a_{20} \cdot x_0 + a_{21} \cdot x_1 + a_{22} \cdot x_2$$

c_{01}

$$a_{03} \cdot x_3 + a_{04} \cdot x_4 + a_{05} \cdot x_5$$
$$a_{13} \cdot x_3 + a_{14} \cdot x_4 + a_{15} \cdot x_5$$
$$a_{23} \cdot x_3 + a_{24} \cdot x_4 + a_{25} \cdot x_5$$

c_{10}

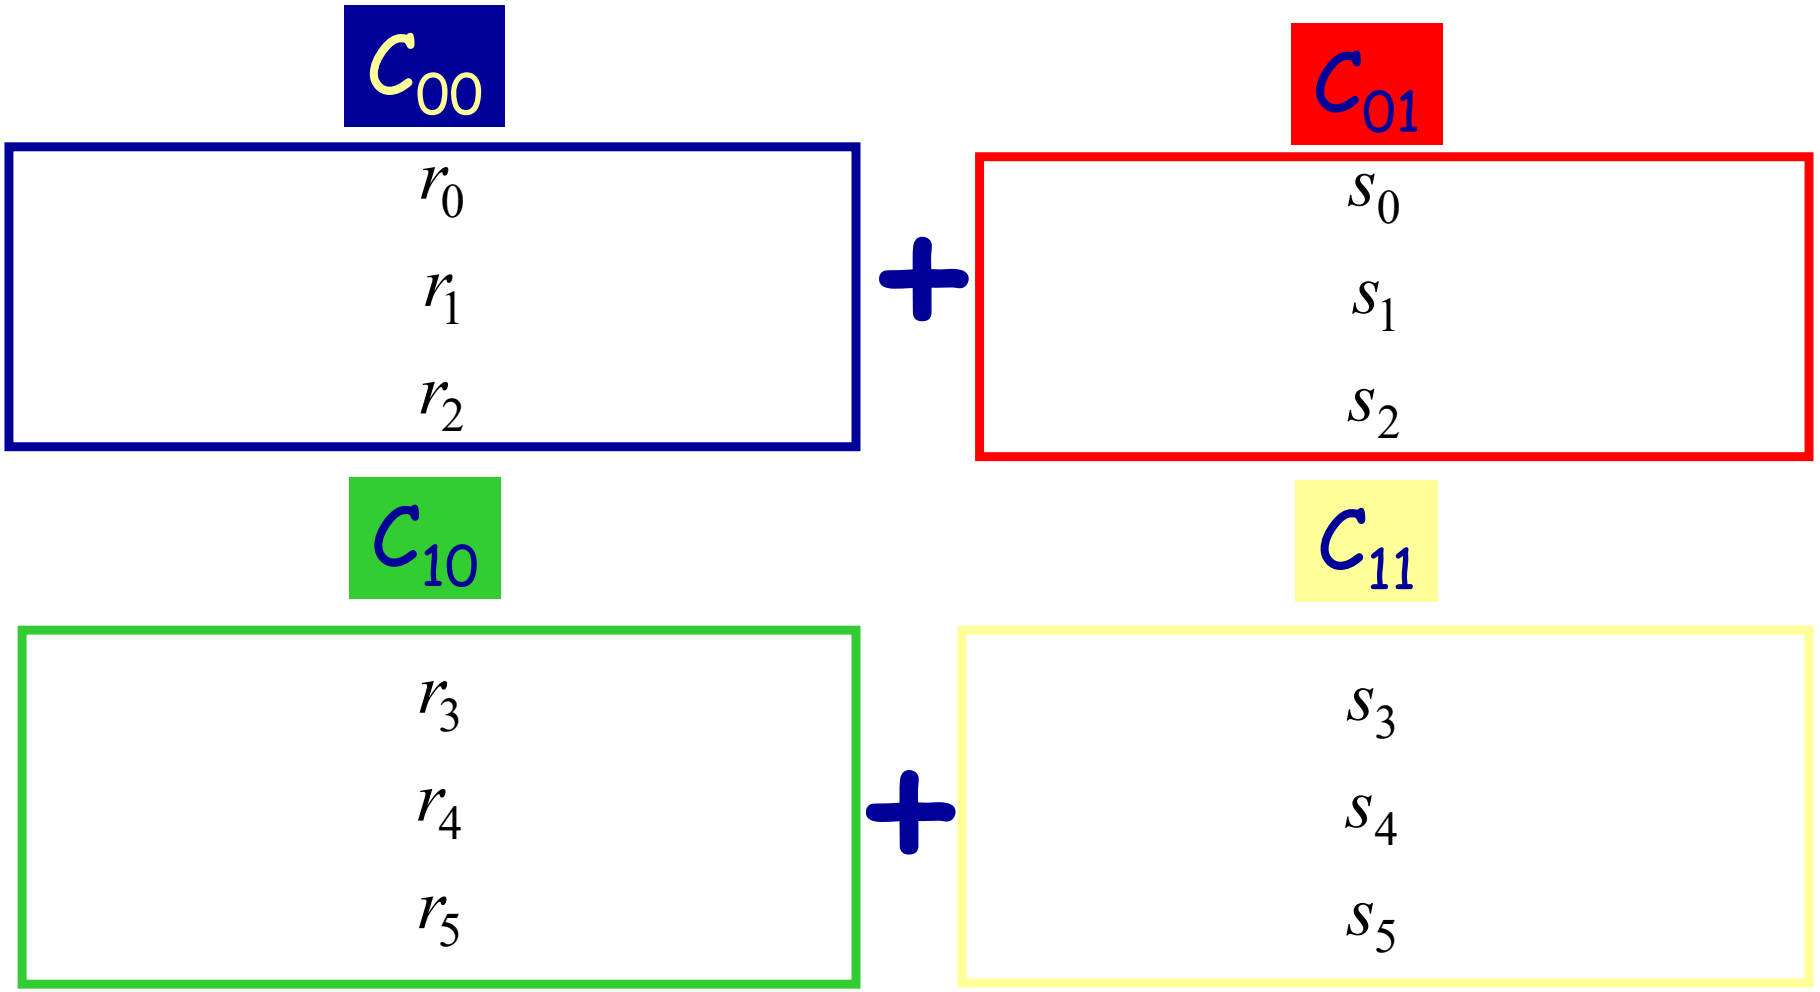
$$a_{30} \cdot x_0 + a_{31} \cdot x_1 + a_{32} \cdot x_2$$
$$a_{40} \cdot x_0 + a_{41} \cdot x_1 + a_{42} \cdot x_2$$
$$a_{50} \cdot x_0 + a_{51} \cdot x_1 + a_{52} \cdot x_2$$

c_{11}

$$a_{33} \cdot x_3 + a_{34} \cdot x_4 + a_{35} \cdot x_5$$
$$a_{43} \cdot x_3 + a_{44} \cdot x_4 + a_{45} \cdot x_5$$
$$a_{53} \cdot x_3 + a_{54} \cdot x_4 + a_{55} \cdot x_5$$

Calcolo dei prodotti parziali

Esempio N = 6 , Core=4



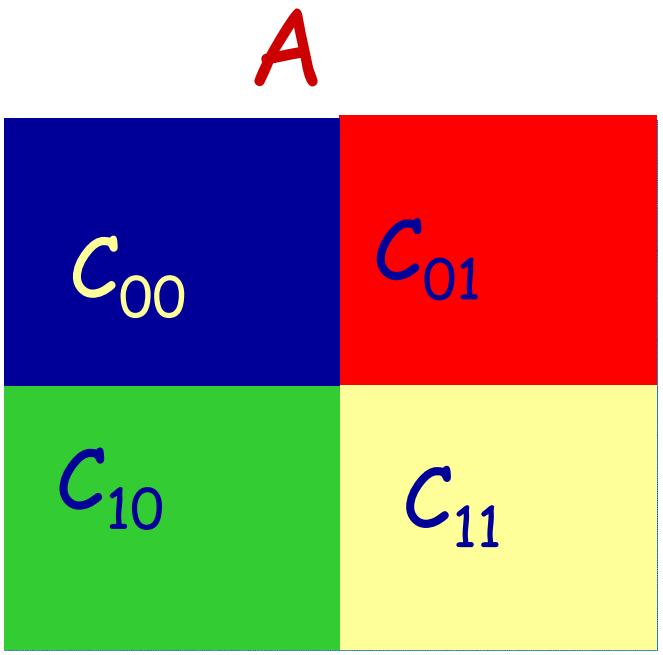
Coo e C_{10} sommano in parallelo

Calcolo **di speedup ed efficienza** (**def classica**)

III Strategia: speed-up/efficienza (**def classica**)

Matrice A: N righe, M colonne, Vettore b: M elementi

$$T_1(N \times M) = N[2M-1]$$



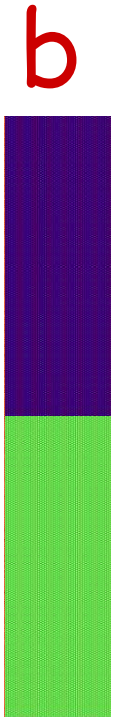
GRIGLIA

qxp=4=2x2 core

III Strategia: speed-up/efficienza (**def classica**)

Matrice A: N righe, M colonne, Vettore b: M elementi

$$T_1(N \times M) = N[2M-1]\, t_{calc}$$



c_{00} Stesso blocco di b

c_{10}

c_{01} Stesso blocco di b

c_{11}

GRIGLIA

qxp=4=2x2 processori

III Strategia: speed-up/efficienza (**def classica**)

Matrice A: N righe, M colonne, Vettore b: M elementi

$\dim[A_{loc}] = (N/q)x(M/p)$

$\dim[b_{loc}] = M/p$

GRIGLIA

qxp=4=2x2 core

Tutti contemporaneamente, **N/q prodotti scalari di lunghezza M/p**, cioè:

N/q [2M/p-1]

N.B.: non è detto che la **GRIGLIA** sia **quadrata**, potrebbe essere anche **rettangolare qxp=8=2x4**

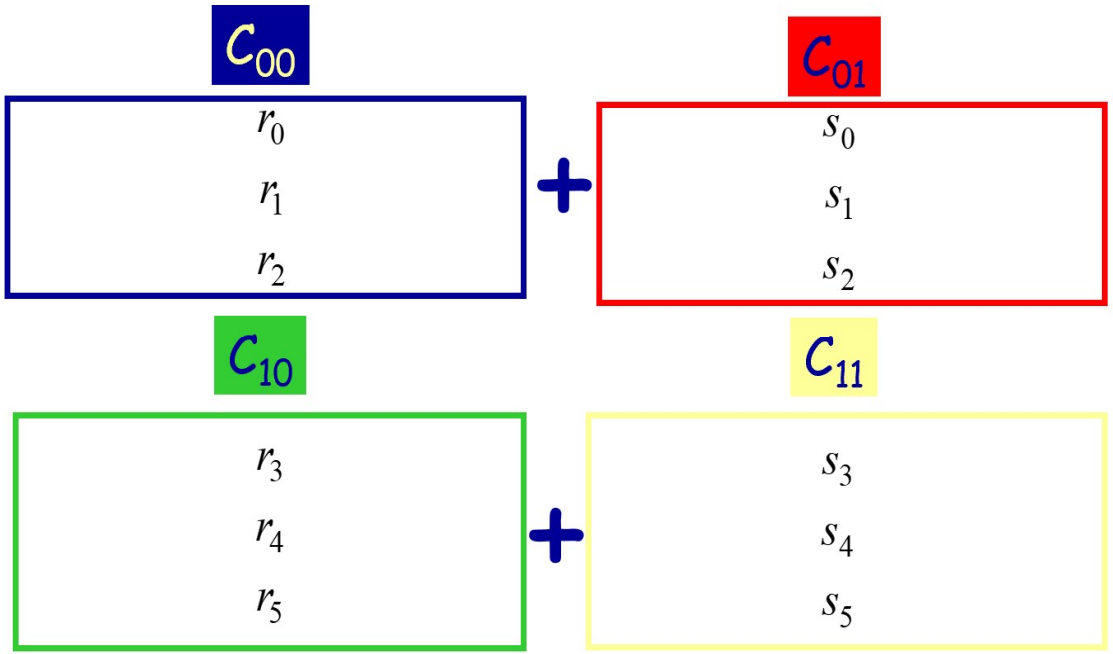
III Strategia: speed-up/efficienza (**def classica**)

Collezione dei risultati:

comunicazione e somma in parallelo

GRIGLIA

qxp=4=2x2 core



III Strategia: speed-up/efficienza (**def classica**)

Collezione dei risultati

La scelta della strategia dipende da quanto vale p.

Se p è potenza di 2 allora conviene la II strategia, altrimenti (ed in particolare se è dispari) conviene usare la I strategia!!!

4=qxp=2x2 p=2

I strategia

I passo (e unico)

C_{00} + C_{01}

C_{10} + C_{11}

C_{00} C_{10} aggiornano il proprio vettore effettuando N/q somme, cioè:

N/q = N/2

III Strategia: speed-up/efficienza (**def classica**)

Collezione dei risultati

4=qxp=2x2 p=2

I strategia

Ho finito.

La complessità computazionale della fase di collezione dei risultati locali vale…

… **in generale:**

(p-1) N/q

III Strategia: speed-up/efficienza (**def classica**)

Matrice A: N righe, M colonne, Vettore b: M elementi

GRIGLIA qxp

I strategia per somma vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$
$$= N[2M-1] /(N/q\ [\ 2M/p-1\ ] + N/q\ (p-1))$$

$$Oh = qxp\ T_{qxp}(NxM) - T_1(NxM) =$$
$$= pxq\ (N/q\ [\ 2M/p-1\ ] + N/q\ (p-1) - N[2M-1]$$

$$E_{qxp}(NxM) = S_{qxp}(NxM) / (qxp)=$$
$$= N[2M-1] / [(qxp)(N/q\ [\ 2M/p-1\ ] + N/q\ (p-1)]$$

III Strategia: speed-up/efficienza (**def classica**)

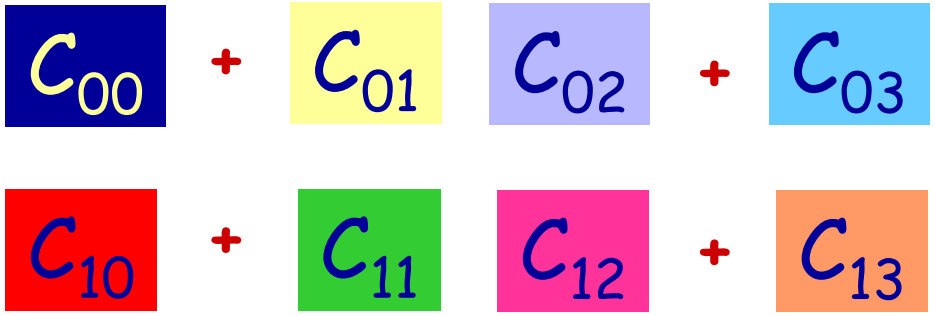
Collezione dei risultati

La scelta della strategia dipende da quanto vale p.

Se p è potenza di 2 allora conviene la II strategia, altrimenti (ed in particolare se è dispari) conviene usare la I strategia!!!

8=qxp=2x4 p=4

II strategia



I passo

c_{00} c_{10} c_{02} c_{12} aggiornano con il proprio vettore effettuando N/q somme, cioè:

N/q = N/2

III Strategia: speed-up/efficienza (**def classica**)

Collezione dei risultati

La scelta della strategia dipende da quanto vale p.

Se p è potenza di 2 allora conviene la II strategia, altrimenti (ed in particolare se è dispari) conviene usare la I strategia!!!

8=qxp=2x4 p=4

II strategia

C_{00} + C_{02}

C_{10} + C_{12}

II passo

C_{00} C_{10} aggiornano con il proprio vettore effettuando altre N/q somme, cioè:

N/q = N/2

III Strategia: speed-up/efficienza (**def classica**)

Collezione dei risultati

matrice A: N righe, M colonne
Vettore b: M elementi

4=qxp=2x2 p=4
II strategia

Ho finito.

La complessità computazionale della fase di collezione dei risultati locali vale…

… **in generale:**

$N/q \cdot \log_2(p)$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

II strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$

$$= N[2M-1] /(N/q\ [\ 2M/p-1\ ] + N/q\ \log_2(p))$$

$$Oh = qxp\ T_{qxp}(NxM) - T_1(NxM) =$$

$$= pxq\ (N/q\ [\ 2M/p-1\ ] + N/q\ \log_2(p)) - N[2M-1]\ t_{calc}$$

$$E_{qxp}(NxM) = S_{qxp}(NxM) / (qxp)=$$

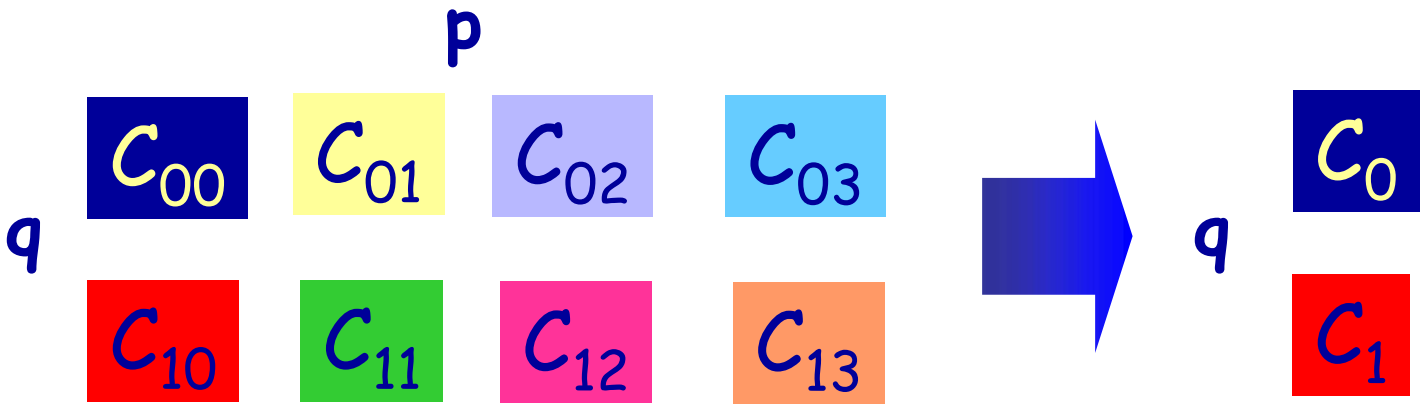
$$= N[2M-1] / [(qxp)(N/q\ [\ 2M/p-1\ ] + N/q\ \log_2(p))]$$

Speed-up/efficienza (**def classica**)

GRIGLIA qxp

Attenzione:

- è possibile riconoscere la I strategia dalla III quando p=1

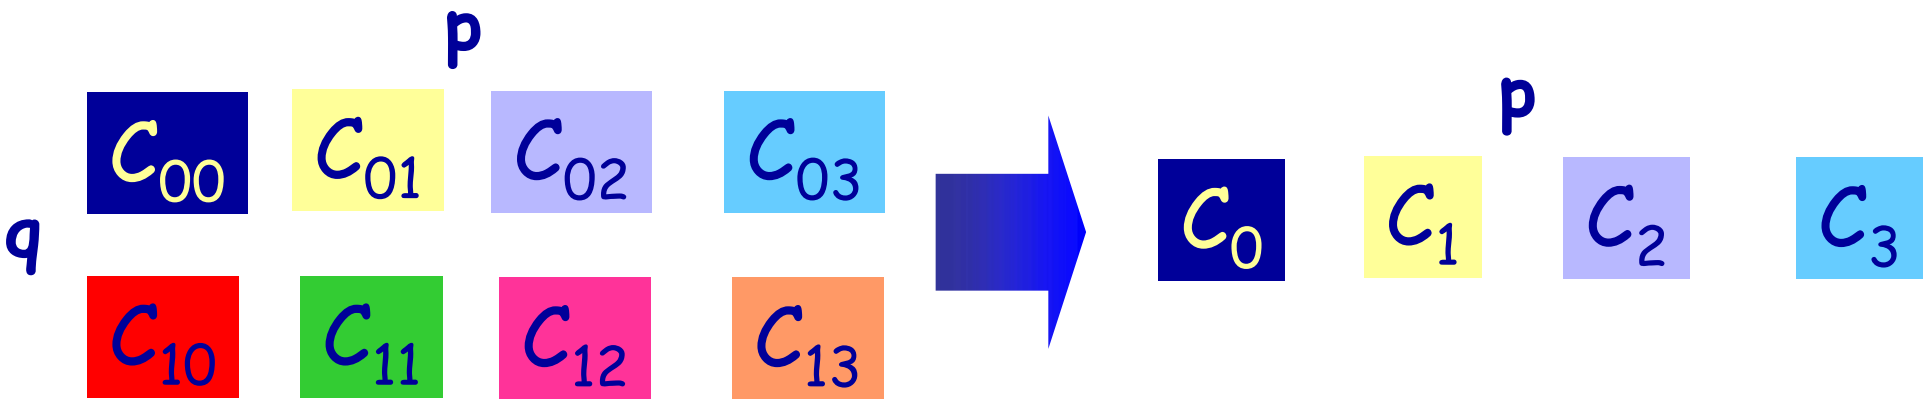


Speed-up/efficienza (**def classica**)

GRIGLIA qxp

Attenzione:

- è possibile riconoscere la I strategia dalla III quando p=1
- è possibile riconoscere la II strategia dalla III quando q=1



Speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

Attenzione:

- è possibile riconoscere la I strategia dalla III quando p=1
- è possibile riconoscere la II strategia dalla III quando q=1
- cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

- **Attenzione:**

  cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

Alcuni core si occuperanno di blocchi di matrice (e se serve del vettore) di dimensione maggiore

Es: RIGHE **mod(N,q)≠0**

Il numero di righe che avanza (cioè il resto della divisione) viene assegnato a tutti i core riga che hanno prima coordinata strettamente minore del resto

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

- **Attenzione:**

  cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

Alcuni processori avranno dei blocchi di matrice (e se serve del vettore) di dimensione maggiore

Es: RIGHE **mod(N,q)≠0**

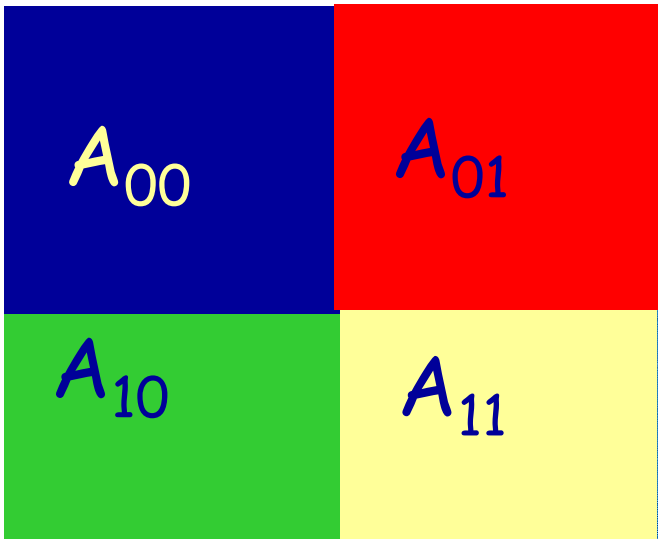
I core che hanno coordinata riga strettamente minore del resto hanno una riga in più della matrice. Nessuna variazione invece per il blocco relativo al vettore!

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

Es: se **mod(N,q) ≠0**

A



GRIGLIA
qxp=4=2x2

$\dim[b_{loc}] = M/p$

$\dim[A_{10}] = (N/q)\,x\,(M/p)$

$\dim[A_{11}] = (N/q)x(M/p)$

$\dim[A_{00}] = (N/q + 1)x(M/p)$

$\dim[A_{01}] = (N/q + 1)x(M/p)$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

Es: se **mod(N,q) ≠0**

GRIGLIA
qxp=4=2x2

$\dim[A_{00}]=(N/q + 1)x(M/p)$

$\dim[A_{01}]=(N/q + 1)x(M/p)$

$\dim[b_{loc}]= M/p$

$\dim[A_{10}]=(N/q)x(M/p)$

$\dim[A_{11}]=(N/q)x(M/p)$

C_{00} C_{01}

C_{10} C_{11}

C_{00}: $\dim[r_{00}]=(N/q + 1)$, C_{01}: $\dim[s_{01}]=(N/q + 1)$

C_{10}: $\dim[r_{10}]=(N/q)$, C_{11}: $\dim[s_{11}]=(N/q)$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

I strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$
$$= N[2M-1] / ([N/q+1] [\ 2M/p-1\ ] + (N/q+1)\ (p-1))$$

II strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$
$$= N[2M-1] / ([N/q+1] [\ 2M/p-1\ ] + (N/q+1)\ \log_2(p))$$

Non resta che calcolare l'overhead e fare osservazioni sull'isoefficienza.

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

- **Attenzione:**

  cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

Alcuni core si occuperanno di blocchi di matrice (e se serve del vettore) di dimensione maggiore

Es: COLONNE **mod(M,p)≠0**

Il numero di colonne che avanza (cioè il resto della divisione) viene ridistribuito a tutti i core colonna che hanno seconda coordinata strettamente minore del resto

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

- **Attenzione:**

  cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

Alcuni core si occuparanno di blocchi di matrice (e se serve del vettore) di dimensione maggiore

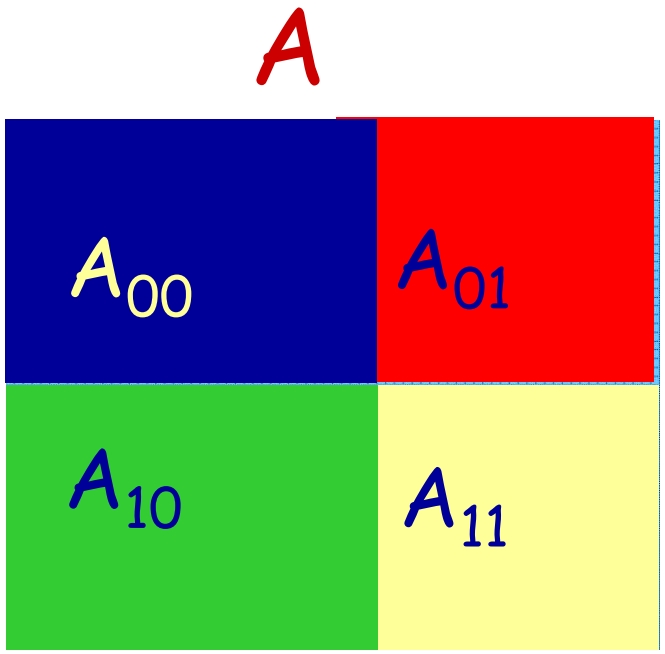
Es: COLONNE **mod(M,p)≠0**

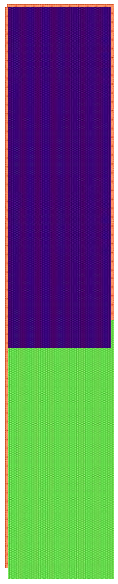
I core che hanno coordinata colonna strettamente minore del resto hanno una colonna in più della matrice e anche un elemento in piu del vettore!

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

Es: se **mod(M,p) ≠0**





GRIGLIA
qxp=4=2x2

$\dim[A_{01}]=(N/q)x(M/p)$
$\dim[A_{11}]=(N/q)x(M/p)$
$\dim[b_1]= M/p$

$\dim[A_{00}]=(N/q\ )x(M/p+1)$

$\dim[b_0]= M/p+1$

$\dim[A_{10}]=(N/q\ )x(M/p+1)$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

Es: se **mod(M,p) ≠0**

$\dim[A_{00}]=(N/q)x(M/p+1)$

$\dim[b_0]= M/p+1$

$\dim[A_{10}]=(N/q)x(M/p+1)$

GRIGLIA
qxp=4=2x2

$\dim[A_{01}]=(N/q)x(M/p)$
$\dim[A_{11}]=(N/q)x(M/p)$
$\dim[b_1]= M/p$

C_{00} C_{01}

C_{10} C_{11}

P_{00}: $\dim[r_{00}]=N/q$, P_{01}: $\dim[s_{01}]=N/q$

P_{10}: $\dim[r_{10}]=N/q$, P_{11}: $\dim[s_{11}]=N/q$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

I strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$

$$= N[2M-1] /(N/q\ [\ (2M/p+1)-1\ ]\ +\ N/q\ (p-1))$$

II strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$

$$= N[2M-1] /(N/q\ [\ (2M/p+1)-1\ ]\ +\ N/q\ \log_2(p))$$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

- **Attenzione:**

  cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

Alcuni core si occuperanno di blocchi di matrice (e se serve del vettore) di dimensione maggiore

Es: RIGHE **mod(N,q)≠0** **e** COLONNE **mod(M,p)≠0**

Il numero delle righe e delle colonne che avanzano (cioè il resto della divisione) verranno ridistribuiti a tutti i core riga e colonna che hanno prima e seconda coordinata strettamente minore del resto

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

- **Attenzione:**

  cosa succede se **mod(N,q) ≠0** e/o **mod(M,p)≠0** ?

Alcuni core si occuperanno di blocchi di matrice (e se serve del vettore) di dimensione maggiore

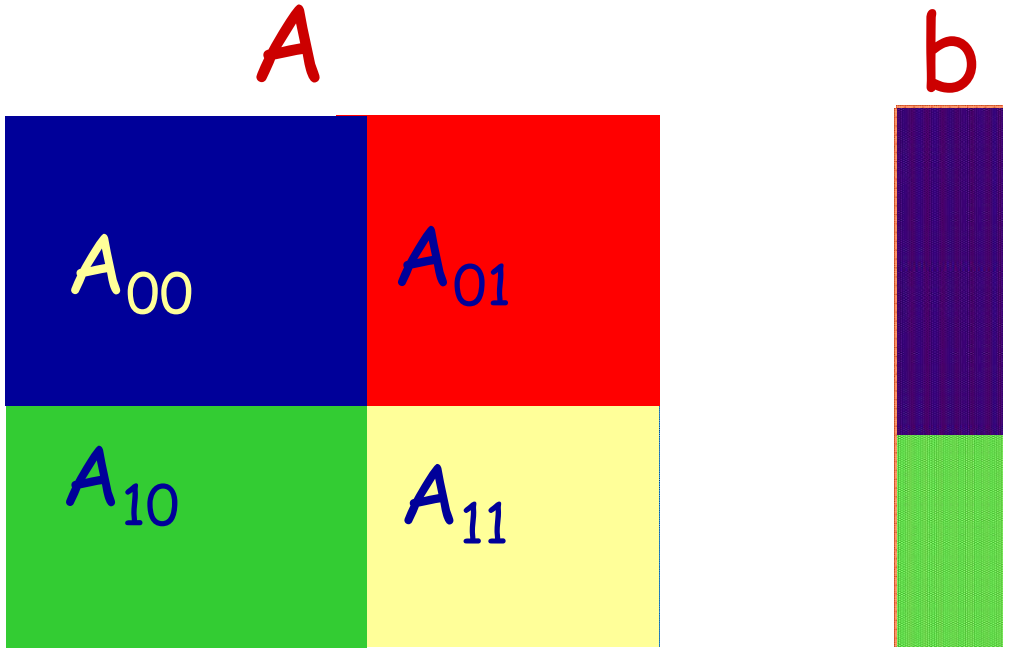
Es: RIGHE **mod(N,q)≠0** **e** COLONNE **mod(M,p)≠0**

I core che hanno coordinata riga e colonna strettamente minore del resto
hanno una riga e una colonna in più della matrice
e anche
un elemento in piu del vettore!

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

Es: se **mod(N,q) ≠0, mod(M,p) ≠0**



GRIGLIA
qxp=4=2x2

$\dim[A_{11}]=(N/q)x(M/p)$
$\dim[b_1]= M/p$

$\dim[A_{00}]=(N/q +1)x(M/p+1)$

$\dim[b_0]= M/p+1$

$\dim[A_{10}]=(N/q)x(M/p+1)$, $\dim[A_{01}]=(N/q+1)x(M/p)$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

Es: se **mod(N,q) ≠0, mod(M,p) ≠0**

GRIGLIA
qxp=4=2x2

$\dim[A_{11}]=(N/q)x(M/p)$
$\dim[b_1]= M/p$

$\dim[A_{00}]=(N/q +1)x(M/p+1)$

$\dim[b_0]= M/p+1$

$\dim[A_{10}]=(N/q)x(M/p+1)$, $\dim[A_{01}]=(N/q+1)x(M/p)$

C_{00} C_{01}

C_{10} C_{11}

P_{00}: $\dim[r_{00}]=N/q+1$, P_{01}: $\dim[s_{01}]=N/q+1$

P_{10}: $\dim[r_{10}]=N/q$, P_{11}: $\dim[s_{11}]=N/q$

III Strategia: speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

I strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$
$$= N[2M-1] / ([N/q+1] [\ 2M/p+1-1\ ] + (N/q+1)\ (p-1))$$

II strategia per collezione vettori

$$S_{qxp}(NxM) = T_1(NxM)/T_{qxp}(NxM) =$$
$$= N[2M-1] / ([N/q+1] [\ 2M/p+1-1\ ] + (N/q+1)\ \log_2(p))$$

Speed-up/efficienza (**def classica**)

matrice A: N righe, M colonne
Vettore b: M elementi

GRIGLIA qxp

Attenzione:

- è possibile riconoscere la I strategia dalla III quando p=1
- è possibile riconoscere la II strategia dalla III quando q=1



Tutti i conti fatti per la III strategia nel caso in cui N non sia esattamente divisibile per q e/o M non sia esattamente divisibile per p, possono essere proiettati per la I strategia (p=1) e per la II strategia (q=1) provate a farvi i conti da soli!

III Strategia: **isoefficienza**

matrice A: N righe, M colonne
Vettore b: M elementi

Per il calcolo dell'isoefficienza è necessario separare i conti tra la I e la II strategia impiegata per la collezione dei risultati!!!

I strategia per collezione vettori

$$Oh = qxp\ (N/q\ [\ 2M/p-1\ ] + N/q\ (p-1)) - N[2M-1] =$$
$$= 2\,NM - pN + p^2\,N - p\,N - 2NM + N =$$
$$= p^2\,N - 2pN + N$$

È uguale a quello della II strategia (con I strategia per collezione vettori): overhead dipende dal numero delle righe e dal numero dei core lungo le colonne!

III Strategia: **isoefficienza**

matrice A: N righe, M colonne
Vettore b: M elementi

uguale a quello della II strategia (con I strategia per collezione vettori)

I strategia per collezione vettori

$$I(q_0\, p_0,\ q_1\, p_1,\ N_0\, M_0) =$$

$$C = [N_1\,(-2p_1 + p_1^2 + 1)]/[N_0\,(-2p_0 + p_0^2 + 1)]$$

$$N_1\, M_1 = C\, N_0\, M_0 =$$

$$= N_0\, M_0\, [N_1\,(-2p_1 + p_1^2 + 1)]/[N_0\,(-2p_0 + p_0^2 + 1)]$$

Nel calcolo delle nuove dimensioni N ed M, devo fissare il numero di righe e calcolare le colonne

III Strategia: **isoefficienza**

matrice A: N righe, M colonne
Vettore b: M elementi

Rifare i conti per la seconda strategia…

II strategia per collezione vettori

$$Oh = qxp\ (N/q\ [\ 2M/p-1\ ] + N/q\ \log_2(p)) - N[2M-1] =$$
$$= 2N\ M - pN + p\ N\ \log_2(p) - 2NM + N =$$
$$= p\ (N\ \log_2(p) - N + 1)$$

Anche in questo caso uguale alla II strategia (con II strategia per collezione vettori): Overhead dipende dal numero delle righe e dei core definiti lungo le righe della griglia virtuale!

II Strategia: **isoefficienza**

matrice A: N righe, M colonne
Vettore b: M elementi

uguale a quello della II strategia (con II strategia per collezione vettori)

II strategia per collezione vettori

$$I(q_0\ p_0,\ q_1\ p_1,\ N_0\ M_0) = C =$$

$$[N_1(-p_1+p_1\ \log_2(p_1)+1)]/[N_0(-p_0+p_0\log_2(p_0)+1)]$$

$$N_1\ M_1 = C\ N_0\ M_0 =$$

$$= N_0\ M_0\ [N_1(-p_1+p_1\ \log_2(p_1)+1)]/[N_0(-p_0+p_0\log_2(p_0)+1)]$$

Stesse osservazioni di prima, nel calcolo delle nuove dimensioni, posso fissare un qualunque numero di righe e calcolare il più opportuno numero di colonne

III Strategia: **isoefficienza**

I conti devono essere rifatti nel caso in cui **mod(N,q) ≠0** e/o **mod(M,p)≠0**

ma la scalabilità è compromessa

Domanda facile d'esame

Se ho una matrice A, di dimensione N=16, M=14; ed un vettore b di dimensione M=14 qual è la migliore strategia parallela, in termini di speedup, se ho 8 core?

Risposta di chi ha capito tutto?

La I… sempre (senza bisogno di fare conti)

Ed esclusa la I? Cioè tra la II e la III?

Conti, calcolatrice alla mano…

Lezioni della settimana prossima

Ultime due lezioni.

Ci vediamo	giovedì 11 alle 14:00
	venerdì 12 alle 14:00